

# Modelos Mistos e Aplicações - Lista 1

Renata Hirota

## 1. Prove que a estatística F do ANOVA tem distribuição F

Um variável aleatória Y tem distribuição  $F_{d_1, d_2}$  se

$$Y = \frac{X_1/d_1}{X_2/d_2}$$

onde  $X_1 \sim \chi_{d_1}^2$  e  $X_2 \sim \chi_{d_2}^2$  são independentes.

Na ANOVA, a estatística F é definida como

$$\frac{QMA}{QME}, \quad QMA = SQA/(t-1), QME = SQE/(N-t)$$

$SQA = \sum_{i=1}^t n(\bar{Y}_{i.} - \bar{Y}_{..})^2$ , ou seja, soma de quadrados de uma diferença de normais. Dividido por  $(t-1)$ , a quantidade de elementos somados, temos uma variável com distribuição qui-quadrado,

$$QMA \sim \chi_{(t-1)}^2$$

O equivalente pode ser dito de SQE e QME, já que SQE é

$$\sum_{i=1}^t \sum_{j=1}^n (Y_{ij} - \bar{Y}_{i.})^2$$

Logo,  $QME \sim \chi_{(N-t)}^2$

Como QME e QMA são independentes, temos que  $F \sim F_{t-1, N-t}$

## 2. MLE para d

Para obter a estimativa de máxima verossimilhança (MLE) para a componente aleatória em um modelo de efeitos mistos, maximizamos a função de verossimilhança condicional.

Dado o modelo

$$Y_{ij} = \beta_0 + b_i + \epsilon_{ij}$$

onde

- $Y_{ij}$  é a observação para o j-ésimo sujeito no i-ésimo nível do tratamento,
- $\beta_0$  é o efeito fixo do intercepto,
- $b_i$  é a componente aleatória associada ao i-ésimo tratamento,
- $\epsilon_{ij}$  é o erro aleatório associado à observação  $Y_{ij}$ .

A função de verossimilhança condicional  $L(\theta|Y)$  é definida como a probabilidade conjunta das observações  $Y_{ij}$ , dadas as estimativas dos parâmetros  $\theta$  (que incluem os efeitos fixos e a variância da componente aleatória)

$$L(\theta|Y) = \prod (Y_{11}, Y_{12}, \dots, Y_{ij}|\theta)$$

$$\ln(L(\theta|Y)) = \sum [\ln(f(Y_{ij}|\theta))]$$

$$\frac{\partial[\ln(L(\theta|Y))]}{\partial(\sigma_b^2)} = 0$$

## 3. Sejam duas variáveis aleatórias G e Y. Prove que Var(G) pode ser escrita como a soma da esperança condicional e variância condicional de Y

Podemos definir a variância de G como

$$Var(G) = E[(G - E[G])^2]$$

Pela esperança condicional, temos

$$Var(G) = E[(E[G|Y] + (G - E[G]))^2]$$

$$Var(G) = E[E[G|Y]^2 + 2(E[G|Y])(G - E[G]) + (G - E[G])^2]$$

$$Var(G) = E[E[G|Y]^2] + 2E[(E[G|Y])(G - E[G])] + E[(G - E[G])^2]$$

$$Var(G) = E[E[G|Y]^2] + 2E[(E[G|Y])(G - E[G])] + E[(G - E[G])^2]$$

O segundo termo é a esperança do produto da esperança condicional  $E[G|Y]$  com a diferença  $(G - E[G])$ , o que é igual a zero, pois a esperança condicional de  $G$  é uma função de  $Y$ . Portanto, esse termo se reduz a zero:

$$Var(G) = E[E[G|Y]^2] + E[(G - E[G])^2]$$

Então,

$$Var(G) = E[Var(G|Y)] + Var(E[G|Y])$$

## 5. PRT

```
dados <- nlmeU::prt.fiber |>
  dplyr::filter(fiber.f == "Type 2") |>
  dplyr::inner_join(nlmeU::prt.subjects, "id")
```

Vamos considerar como efeitos aleatórios os participantes, com as seguintes variáveis associadas a eles:

Participante (`id`):

- Sexo (`sex.f`)
- Idade (`age.f`)
- IMC (`bmi`)

Consideraremos como efeito fixo:

- Intensidade do treinamento (`prt.f`)
- Ocasão (`occ.f`)

A variável resposta é a medida de força específica da fibra muscular (`spec.fo`)

## Modelo

$$Y = XB + ZU + E$$

- $Y$  é um vetor de observações da variável de resposta `spec.fo`
- $X$  é a matriz de covariáveis fixas, incluindo um vetor de uns para o intercepto e as covariáveis `prt.f`, `age.f`, `sex.f`, `bmi` e `occ.f`.
- $B$  é um vetor de coeficientes correspondentes às covariáveis fixas, incluindo o intercepto.
- $Z$  é a matriz de desenho do efeito aleatório, que contém um vetor de uns para a unidade de agrupamento  $i$
- $U$  é um vetor de efeitos aleatórios  $u_i$  associados a cada unidade de agrupamento (`id`), modelado como  $u_i \sim N(0, \sigma_u^2)$
- $E$  é um vetor de erros residuais  $\epsilon_{ij}$  para cada observação, modelado como  $\epsilon_{ij} \sim N(0, \sigma^2)$

```
fit <- nlme::lme(  
  spec.fo ~ 1 + prt.f + age.f + sex.f + bmi + occ.f,  
  random = ~ 1|id,  
  data = dados  
)  
summary(fit)
```

Linear mixed-effects model fit by REML

Data: dados

	AIC	BIC	logLik
	11187.58	11228.07	-5585.789

Random effects:

Formula: ~1 | id

(Intercept) Residual

StdDev: 13.56403 27.49065

Fixed effects: spec.fo ~ 1 + prt.f + age.f + sex.f + bmi + occ.f

	Value	Std.Error	DF	t-value	p-value
(Intercept)	149.46213	15.432129	1108	9.685127	0.0000
prt.fLow	-1.61267	3.847214	58	-0.419179	0.6766
age.fOld	6.96845	3.877306	58	1.797240	0.0775
sex.fMale	-4.37663	3.864605	58	-1.132491	0.2621
bmi	0.60780	0.589132	58	1.031689	0.3065
occ.fPos	8.50944	1.661194	1108	5.122487	0.0000

Correlation:

(Intr) prt.fL ag.fOl sx.fMl bmi

```

prt.fLow  -0.193
age.fOld  -0.242  0.013
sex.fMale -0.028 -0.044 -0.006
bmi       -0.966  0.072  0.106 -0.085
occ.fPos  -0.058  0.003  0.031  0.011 -0.005

```

Standardized Within-Group Residuals:

	Min	Q1	Med	Q3	Max
	-3.03668536	-0.65887912	-0.03786059	0.61449852	3.98073017

Number of Observations: 1172

Number of Groups: 63

A variância dos efeitos aleatórios é alta, o que indica que de fato o modelo misto é adequado.

Observamos também que há baixa correlação entre os efeitos fixos, o que descarta uma possível multicolinearidade.

No entanto, não parece haver efeito significativo da variável de interesse `prt.f` (intensidade do treinameto) na variável resposta (`spec.fo`), mas sim da ocasião em que o treino ocorre (`occ.f`).